Syntax natürlicher Sprachen

Vorlesung 1: Intro

A. Wisiorek

Centrum für Informations- und Sprachverarbeitung,
Ludwig-Maximilians-Universität München

19.10.2021

Themen der heutigen Vorlesung

1. Übersicht
2. Programmsysteme
3. Syntaxanalyse mit NLTK

Begleitende Literatur

- Bird, Steven, Ewan Klein und Edward Loper (2009). *Natural language processing with Python: analyzing text with the natural language toolkit*. URL: `http://www.nltk.org/book/`.
- Dürscheid, Christa (2010). *Syntax: Grundlagen und Theorien*. Bd. 3. Vandenhoeck & Ruprecht.

1. Übersicht

Inhalte

- Die Vorlesung behandelt **Grundbegriffe der Grammatik** und wesentliche syntaktische Konstruktionen des Deutschen im Hinblick auf eine **Verwendung in der maschinellen Sprachverarbeitung**
- Dazu werden die in neueren Grammatiktheorien verwendeten **Klassifizierungen von Phrasen**, deren **innere Struktur** sowie deren **relationale Abhängigkeiten** erklärt.
- Außerdem werden in der Computerlinguistik übliche **Grammatikformalismen** (wie Kontextfreie Grammatiken, Unifikationsgrammatiken, PCFGs, Datenbasierte Dependenzgrammatiken, Partielle Parsingmodelle)
- ebenso wie **syntaktische Annotationsstandards** (z.B. Penn Treebank, Universal Dependencies) vorgestellt und verwendet, um typische oder schwierige syntaktische Konstruktionen genau zu beschreiben.

Lernziele

- Kenntnis und Anwendung **funktionaler und struktureller Begriffe der grammatischen Beschreibung**:
  - **Kongruenz**
  - **Rektion**
  - **Subkategorisierung**
  - **Valenz**
- Kenntnis **Grammatikformalismus** und Anwendung für Analysen natürlichsprachlicher Sätze:
  - **CFG** (Kontextfreie Grammatik: *Konstituentenstruktur*)
  - **FCFG** (Feature-based CFG: *Modellierung grammatischer Merkmale*)
  - **PCFG** (Probabilistische CFG: *Gewichtung von CFG-Regeln*)
  - **DG** (Dependency Grammar: *Dependenzstruktur*)
  - **Chunk-Parser** (u.a. RegExpParser: *partielles Parsing*, *'Parsing as Tagging'*)
- Kenntnis und Bedienung eines **Programmsystems**, das einen Grammatikformalismus verwendet

2. Programmsysteme

Parsingsystem I: NLTK

NLTK: *Anwendung regelbasierter Parsing-Grundlagen*

- Schreiben von Grammatikregeln und Anwendung in Parsingalgorithmen
- konstituentenbasierte sowie dependenzbasierte Grammatiken
- 'Toy Grammar' für einzelne Beispielsätze

Informationen zum NLTK (Natural Language Toolkit)

- Bündel von Python-Bibliotheken und Programmen für computerlinguistische Anwendungen
- quelloffen, für Lehre entwickelt
- bietet auch Interfaces, z.B. für *Stanford Parser*
- Lehrbuch: `http://www.nltk.org/book`
- Dokumentation: `http://www.nltk.org/howto`
- Daten (Korpora, Grammatiken): `http://www.nltk.org/data.html`

Parsingsystem II: spaCy

spaCy: *NLP-System mit Dependency-Parser*

- modernes, deep-learning-basiertes NLP-System
- aus Korpora gelernte, umfangreiche Syntax-Modelle
- basierend auf Dependency-Treebanks
  - Beispiel einer **Dependency-Treebank**:
    `https://github.com/UniversalDependencies/UD_German-GSD/blob/master/de_gsd-ud-dev.conllu`
- 'transition-based **Dependency-Parsing**':
  `https://spacy.io/api/dependencyparser/`

Parsingsystem III: Stanford Parser

Stanford-Parser: *NLP-System mit induzierten PCFG-Modellen*

- aus Korpus gelernte, kontextfreie Grammatikregeln mit Gewichtung
- **Konstituentenbasiertes Modell**, basierend auf CFG-Treebank
- Grundlage des englischen Modells ist die **Penn-Treebank**:
  - `https://catalog.ldc.upenn.edu/docs/LDC95T7/cl93.html`
  - Sample der Penn-Treebank in NLTK-Data enthalten

Hinweis

DerStanford-Parser wird im Kurs nur für Beispielanalysen herangezogen, nicht aktiv in der Übung verwendet! (ist als Online-Demo verfügbar)

Dependenzanalysen mit Stanford-Parser

- von CFG-Syntaxbaum abgeleitete Dependenz-Analysen
- **UD-Format** ('Universal Dependencies'):
  `https://universaldependencies.org/u/dep/`

Demos Stanford-Parser

Demos

- `http://nlp.stanford.edu:8080/parser/index.jsp`
- `https://corenlp.run/`

3. Syntaxanalyse mit NLTK

Parsing als automatische Syntaxanalyse

Aufgaben eines Parsingalgorithmus

1. **Überprüfung** der grammatischen Struktur einer Eingabe auf Wohlgeformtheit
   → ***Suche einer Ableitung*** *gemäß der Regeln einer formalen Grammatik*
2. **Wiedergabe** der gefundenen grammatischen Struktur
   → ***Ableitungsbaum*** *(auch: Parsebaum, Syntaxbaum)*

Grammatik-Typen im NLTK

Haupttypen

1. **CFGs** (kontextfreie Grammatiken)
   - Konstituentenstruktur (Phrasenstrukturgrammatik)
   - Strukturinformationen in den Knoten des Syntaxbaums
2. **Dependenzgrammatiken**
   - Abhängigkeitsrelationen zwischen Wörtern
   - Strukturinformationen in den Kanten des Syntaxbaums (Relationslabel)
3. **Chunk-Parser** (u.a. reguläre Grammatiken)
   - partielle Syntaxanalyse (nur wichtigste Konstituenten: NPs, VPs, PPs)
   - flache, nicht-hierarchische Strukturanalyse

Erweiterungen von CFGs

1. **PCFGs** (Probabilistische CFGs)
2. **FCFGs** (Feature-based-CFGs)

Strukturelle Ambiguität

Problem

- mehr als eine Position im Syntaxbaum möglich

Lösung

- Disambiguierung u.a. über Probabilistische CFGs (**PCFGs**)

Beispielsatz für PP-Attachment

- *One morning **I shot an elephant in my pajamas**.*

  How he got into my pajamas I don't know.

  (Groucho Marx, Animal Crackers, 1930)

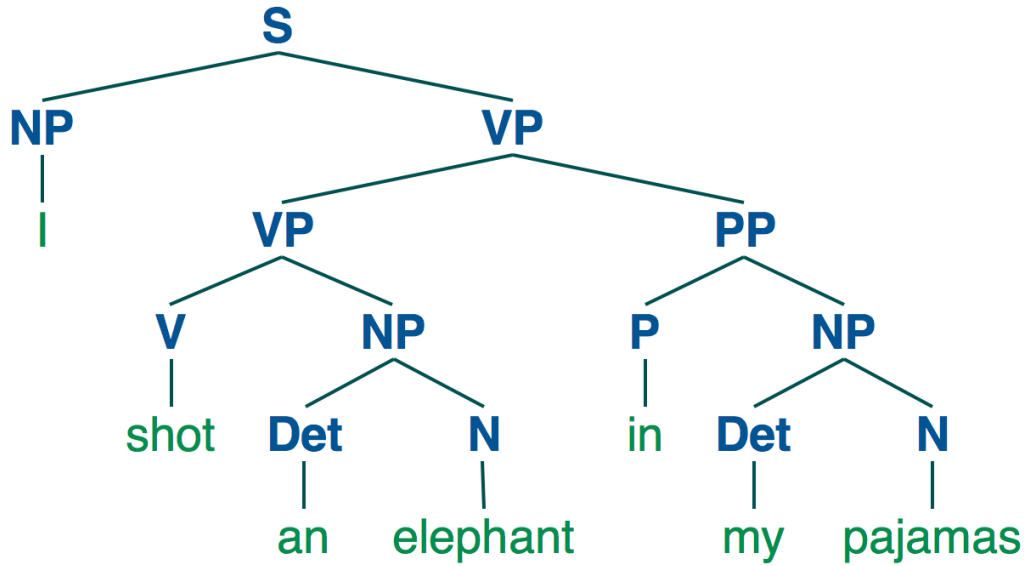
S
NP
VP
I
VP
PP
V
NP
P
NP
shot
Det
N
in
Det
N
an
elephant
my
pajamas

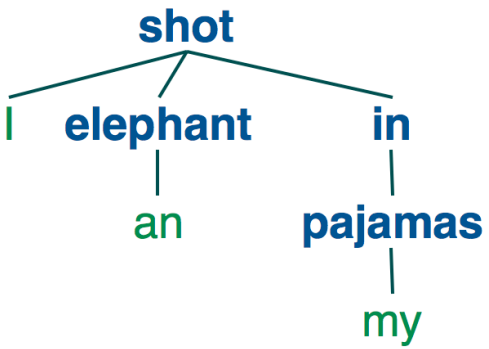
shot
I
elephant
in
an
pajamas
my

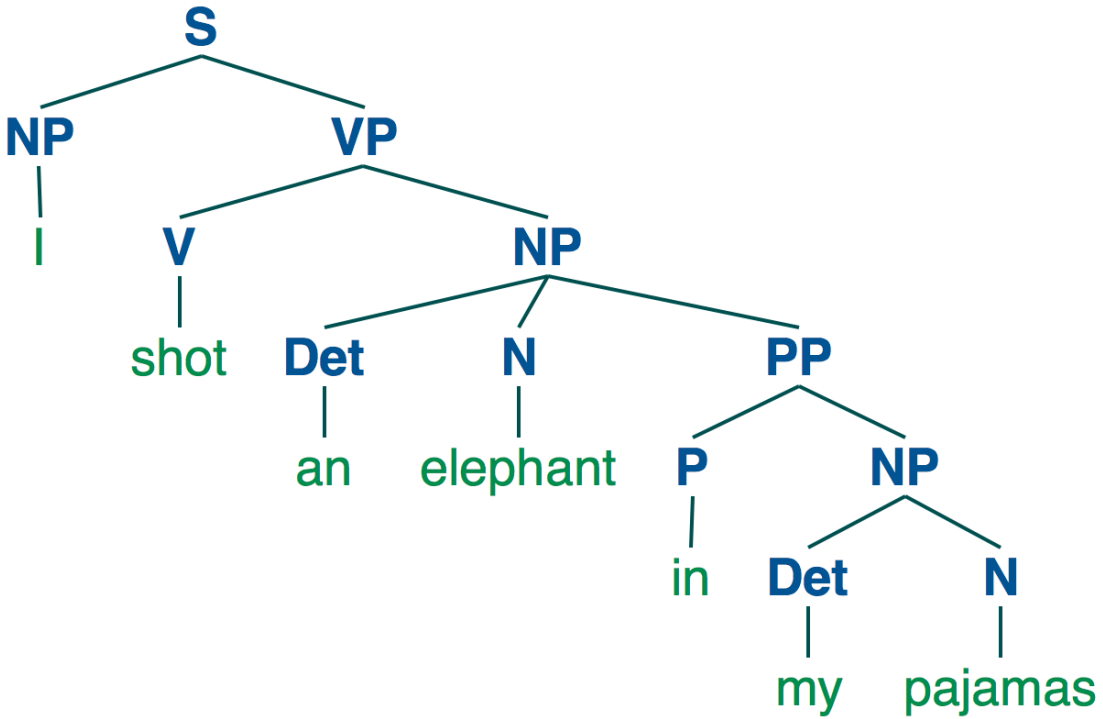
S
NP
VP
I
V
NP
shot
Det
N
PP
an
elephant
P
NP
in
Det
N
my
pajamas

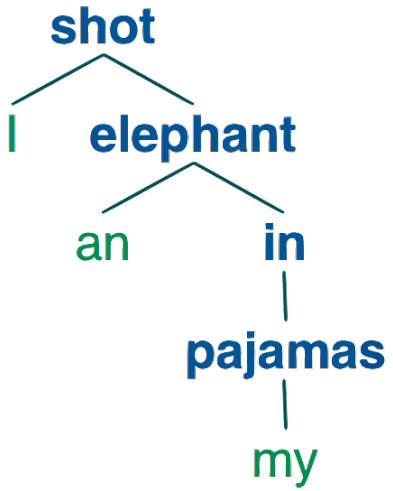
shot
I
elephant
an
in
pajamas
my

Übergenerierung (en. *overgeneration / overproduction*)

Problem

- CFG-Regeln einer Grammatik erzeugen (neben den zu erkennenden Beispielsätzen) auch nicht-wohlgeformte Sätze
- Grund: Nichtberücksichtigung morphologischer Constraints wie:
  - Kasusrektion
  - Kongruenz (Agreement)
  - Subkategorisierung (Art und Anzahl von Argumenten)

Lösung

- Modellierung morphologischer Constraints über Merkmalsstrukturen mit **Feature-based-CFGs** (FCFGs)

Beispiel für Übergenerierung

- CFG-Regeln für: *I shoot*, *He shoots*
- Übergenerierung: *I shoots*, *He shoot*

NLTK-Kapitel

NLTK-Kapitel zu den Parsing-Beispielen

- **NLTK-Kapitel 8:** `https://www.nltk.org/book/ch08.html`
  → *Parsing mit CFGs, Dependenzgrammatiken, PCFGs*
- **NLTK-Kapitel 9:** `https://www.nltk.org/book/ch09.html`
  → *Parsing mit feature-based grammars*
- **NLTK-Kapitel 7:** `https://www.nltk.org/book/ch07.html`
  → *partielles Parsing mit RegexpParser*

Rückblick auf heutige Themen

1. Übersicht
2. Programmsysteme
3. Syntaxanalyse mit NLTK